

FastSpeech 2 와 Fine-tuning 전이 학습을 이용한 학습 목적의 개인화 TTS 구현

영우글로벌러닝 AI 7기 양창은

기업연계 대체 개인 프로젝트 (2022/08/27 ~ 2022/10/05)



본 프로젝트는 상업적, 수익화 목적이 일절 없으며,
개인적인 학습 목적으로 진행되었습니다.

본 프로젝트는 동일 과정 AI 2기 전유상, AI 7기 이정훈님의
작은 도움을 받아 진행된 개인 고유의 프로젝트이며,
도움을 주신 두 분과 학습 환경을 제공해준
영우글로벌러닝에게 감사의 말씀을 전합니다.



프로젝트 진행 개요

- Part 1 : 구현 계획
- Part 2 : 데이터셋 제작
- Part 3 : 모델 구현
- Part 4 : 모델 학습 및 성능 평가

P1 : 구현 계획

P1 : 구현 계획

- What : 단시간 내에 제작하여 좋은 성능을 낼 수 있는 개인화 TTS
- How : 양질의 큰 데이터셋으로 충분히 학습된 pretrained model에
직접 준비한 적은 양의 데이터셋으로 fine-tuning하여 전이 학습
- Why : 준비된 pretrained model만 있으면 누구나 10분 분량 내외의
적은 데이터셋만으로도 단시간에 자신만의 TTS를 만들 수 있는
TTS 개인화 제작 시스템 구현을 위해

P1 : 구현 계획

- Who : TTS 화자 대상 선정
 - Pretrained model : KSS dataset - Korean Single Speaker Speech Dataset, Kyubyong Park
(학습 목적으로만 사용이 허용된 12시간 분량의 양질의 데이터셋)
 - Transfer learning : 아이유(이지은) dataset - 10분 내외 분량으로 직접 제작
- When : 예상 소요 시간 계획

데이터셋 제작 (65%)	모델 구현 (15%)	모델 학습 (20%)
---------------	----------------	----------------

2022/08/27

2022/10/05

P2 : 데이터셋 제작



P2 : 데이터셋 제작

- Wondershare UniConverter 14 유료 프로그램
 - 아이유의 발화가 담긴 Youtube 영상의 원본 영상과 소리 추출을 위해 사용
 - EDAM Entertainment 채널에 업로드 된
‘[집콕시그널] 아이유와 함께하는 집콕바캉스 (Live) [Full]’ 영상
- 1시간 28분 40초 분량의 320kbps MP3 형식으로 소리 추출

< 홈

변환

다운로드

영상 줄이기

동영상 편집

동영상 합치기

화면 녹화

DVD 굽기

공구함



다운로드중

완료

고속 다운로드



https://youtu.be/YPckl1tIktw

일시 중지

재개

설정

일반 변환 다운로드 위치 계정 자막 프록시

최대 다운로드 작업수: 5

☒ YouTube에서 원클릭 다운로드 모드:

다운로드: 오디오 품질: 320Kbps 자막: English

☒ 자막/CC 자동 다운로드

☒ 시작시 완료되지 않은 작업을 자동으로 재개

☒ 자막/CC를 출력 동영상에 병합

재설정



다운로드 후 변환 모드

파일 저장 위치: C:\Wondershare UniConverter

모두 시작

모두 일시정지

내 파일




검색하려면 여기에 입력하십시오.



오전 11:59
2022-09-30

P2 : 데이터셋 제작

- Audacity 무료 프로그램
 - 영상의 00:04:40 ~ 01:18:40 부분 사용하여 WAV 형식으로 변환
 - 00:03:05.5 ~ 00:03:06.5 부근 및 00:03:52.8 ~ 00:03:55.0 부근
노이즈 활용하여 노이즈 Reduction
 - 의미 있는 발화가 담긴 부분만 잘라서 문장 단위로 음성 파일 저장
 - 총 181개 파일 / 총 분량 11분 25초 / 샘플레이트 44100Hz / Signed 16-bit PCM



P2 : 데이터셋 제작

- Script Labeling
 - 국립국어원 표준 발음법 규정에 따른 음가 변화에 따라 CSV 파일로 script 작성
 - 표준 발음법과 실제로 들리는 발음을 절충, 참고하여 모든 음성 파일에 대해 병기하여 작성
 - 평서문, 의문문, 숨소리에 해당하는 음가는 각각 마침표, 물음표, 쉼표로 구분
 - 예시) 어, 이게 이틀만에 모인 숫자 라고는 믿어지지 않을 정도로
-> [어 이게 이틀?마네, 모인 숫자라고는 미더지지아늘정도로]

0071



목록 저장(S)	
저장 안 한 목록	
0070	0:01
0071	0:07
0072	0:02
0073	0:03
0074	0:07
0075	0:03
0076	0:01
0077	0:01
0078	0:05
0079	0:02
0080	0:02
0081	0:04
0082	0:05
0083	0:03
0084	0:01
0085	0:03
0086	0:05
0087	0:01
0088	0:01
0089	0:01
0090	0:02
0091	0:03
0092	0:01
0093	0:02
0094	0:01
0095	0:01
0096	0:03
0097	0:01
0098	0:02
0099	0:03
0100	0:02
0101	0:02
0102	0:02
0103	0:06
0104	0:04
0105	0:06
0106	0:04
0107	0:01
0108	0:02
0109	0:01
0110	0:03
0111	0:04
0112	0:02

00:01



파일 홈 삽입 페이지 레이아웃 수식 데이터 검토 보기 도움말

열린 고딕 11

클립보드 글꼴 맞춤 표시 형식 스타일 셀 편집

A1		X ✓ f 0001.wav	
A	B	C	D
71	0071.wav	이천 소	이천 소
72	0072.wav	제 공인	제 공인
73	0073.wav	특별한	특별한
74	0074.wav	우리 다	우리 다
75	0075.wav	이걸 소	이걸 소
76	0076.wav	진짜 조	진짜 조
77	0077.wav	지가압	지가압
78	0078.wav	응건 지	응건 지
79	0079.wav	제 제도	제 제도
80	0080.wav	이거 총	이거 총
81	0081.wav	제주민	제주민
82	0082.wav	채팅창	채팅창
83	0083.wav	엄청마	엄청마
84	0084.wav	누나 오	누나 오
85	0085.wav	병워네	병워네
86	0086.wav	모두가	모두가
87	0087.wav	상황그	상황그
88	0088.wav	상황극	상황극
89	0089.wav	물디브	물디브
90	0090.wav	모히또	모히또
91	0091.wav	이러케	이러케
92	0092.wav	고마솜	고마솜
93	0093.wav	이거또	이거또
94	0094.wav	잘만든	잘만든
95	0095.wav	정재명	정재명
96	0096.wav	정재명	정재명
97	0097.wav	이달날	이달날
98	0098.wav	아아, 다	아아, 다
99	0099.wav	이걸 다	이걸 다
100	0100.wav	아무것	아무것
101	0101.wav	애플민	애플민
102	0102.wav	여기에	여기에
103	0103.wav	저걸도	저걸도

저작권 문제로
상세 내용은
가렸습니다.

P3 : 모델 구현

P3 : 모델 구현

- Korean FastSpeech 2 – Pytorch Implementation




Figure 1: The overall architecture for FastSpeech 2 and 2s. LR in subfigure (b) denotes the length regulator operation proposed in FastSpeech. LN in subfigure (c) denotes layer normalization. Variance predictor represents duration/pitch/energy predictor.


P3 : 모델 구현

- Preprocessing – MFA(Montreal Forced Aligner) Training

- FastSpeech 2 학습을 위해 반드시 필요한

음성과 스크립트 간의 duration을 추출하기 위해 사용

- 1. wav-lab pair 생성
 - 2. lexicon 파일 생성
 - 3. textgrid 파일 생성



2. lexicon 파일

3. textgrid 파일

```
phone : ['ㅈ', 'ㅣ', 'ㄴ', 'ㅌ', 'ㄴ', 'ㅁ', 'ㅊ', 'ㄴ', 'ㅁ', 'ㅡ', 'ㅇ', 'ㅣ', 'ㅉ', 'ㅌ', 'ㅇ', 'ㅣ', 'ㅁ', 'ㅡ', 'ㅎ', 'ㅌ', 'ㅉ', 'ㅅ', 'ㅈ']  
duration: [11 2 4 3 7 1 6 5 9 1 1 7 1 4 4 5 1 1 1 5 51 1 0]  
start : 0.42  
,end : 1.95  
  
phone : ['ㅇ', 'ㅣ', 'ㅇ', 'ㅣ', 'ㅈ', 'ㅊ', 'ㅇ', 'ㅊ', 'ㅇ', 'ㅎ', 'ㅌ', 'ㄴ', 'ㄷ', 'ㅈ', 'ㅅ', 'ㅊ', 'ㄴ', 'ㅌ', 'ㅎ', 'ㅊ', 'ㄴ', 'ㅈ', 'ㅌ']  
duration: [1 4 0 45 11 13 1 1 9 1 6 8 4 3 5 6 1 14 1 3 7 4 6 1  
17 1 4 14 1 3 1 16 1 3 0 37 1 2]  
start : 0.16  
,end : 3.13  
  
phone : ['ㅅ', 'ㅈ', 'ㅇ', 'ㅁ', 'ㅌ', 'ㅇ', 'ㅇ', 'ㅡ', 'ㅉ', 'ㅊ', 'ㅈ', 'ㅣ', 'ㄴ', 'ㅈ', 'ㅈ', 'ㅌ', 'ㅇ', 'ㅊ', 'ㅉ', 'ㅈ', 'ㅈ', 'ㄴ', 'ㅇ', 'ㅌ', 'ㄴ']  
duration: [6 1 12 1 12 11 0 1 1 6 14 3 6 7 4 1 2 1 12 10 0 3 14 2]  
start : 0.0  
,end : 1.52  
  
phone : ['ㅇ', 'ㅣ', 'ㄷ', 'ㅌ', 'ㅇ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㄴ', 'ㅊ', 'ㅈ', 'ㅈ', 'ㅅ', 'ㅇ', 'ㅍ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㅇ', 'ㅡ', 'ㅉ', 'ㅊ']  
duration: [1 16 6 12 2 9 2 11 3 11 3 8 4 1 22 2 1 1 1 1 0 1 3 14  
3 1 1 2 1 3 2 1 3 1 1 0 3 4 17 19 10]  
start : 0.09  
,end : 2.49  
  
phone : ['ㅇ', 'ㅌ', 'ㅇ', 'ㅡ', 'ㅈ', 'ㅊ', 'ㄷ', 'ㅊ', 'ㅇ', 'ㅊ', 'ㅣ', 'ㅁ', 'ㅊ', 'ㅉ', 'ㅅ', 'ㅌ', 'ㅇ', 'ㅣ', 'ㄷ', 'ㅈ', 'ㅈ', 'ㅌ']  
duration: [0 12 0 4 7 6 5 3 0 3 1 8 1 3 7 9 1 1 9 2 7 1 15 6]  
start : 0.0  
,end : 1.29  
  
phone : ['ㅇ', 'ㅊ', 'ㅇ', 'ㅡ', 'ㅇ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㅡ', 'ㄷ', 'ㅌ', 'ㅇ', 'ㅌ']  
duration: [1 6 15 16 1 2 2 0 11 2 30 5]  
start : 0.37  
,end : 1.42  
  
phone : ['ㅇ', 'ㅊ', 'ㅇ', 'ㅊ', 'ㅇ', 'ㅈ', 'ㅈ', 'ㅈ', 'ㅡ', 'ㅌ', 'ㅈ']  
duration: [1 12 11 11 1 2 1 37 1 20]  
start : 0.06  
,end : 1.19
```

Preprocessing – Duration 측정

P3 : 모델 구현

- Pretrained Model
 - VocGAN (neural vocoder)
 - HGU-DLLAB에서 제공한 Checkpoint
(KSS dataset으로 350,000 steps 학습된 가중치)

P4 : 모델 학습 및 성능 평가



P4 : 모델 학습 및 성능 평가

- Google Colab Pro 환경에서 Google Drive 연동 후 학습 진행
- Checkpoint path에 350,000 steps 학습된 pretrained model의 가중치 저장
- 학습 환경에 맞게 코드 작성 및 하이퍼 파라미터 조정
- 앞서 전처리한 아이유 데이터셋으로 150,000 steps 추가 전이 학습 (fine-tuning)
- 10,000 steps마다 checkpoint를 저장하여 loss 및 생성된 음성 파일의 품질 비교




```
Epoch [3300/5000], Step [492000/200000]:  
Total Loss: 0.0754, Mel Loss: 0.0173, Mel PostNet Loss: 0.0149, Duration Loss: 0.0126, F0 Loss: 0.0111, Energy Loss: 0.0194;  
Time Used: 14261.992s, Estimated Time Remaining: -25078.640s.  
66% 3324/5000 [3:59:23<1:58:18, 4.24s/it]  
Epoch [3325/5000], Step [493000/200000]:  
Total Loss: 0.0839, Mel Loss: 0.0177, Mel PostNet Loss: 0.0153, Duration Loss: 0.0193, F0 Loss: 0.0143, Energy Loss: 0.0172;  
Time Used: 14368.113s, Estimated Time Remaining: -24219.568s.  
67% 3349/5000 [4:01:10<1:56:54, 4.25s/it]  
Epoch [3350/5000], Step [494000/200000]:  
Total Loss: 0.0873, Mel Loss: 0.0177, Mel PostNet Loss: 0.0153, Duration Loss: 0.0218, F0 Loss: 0.0140, Energy Loss: 0.0185;  
Time Used: 14474.347s, Estimated Time Remaining: -25162.358s.  
67% 3374/5000 [4:02:56<1:54:55, 4.24s/it]  
Epoch [3375/5000], Step [495000/200000]:  
Total Loss: 0.0804, Mel Loss: 0.0172, Mel PostNet Loss: 0.0148, Duration Loss: 0.0202, F0 Loss: 0.0117, Energy Loss: 0.0164;  
Time Used: 14580.559s, Estimated Time Remaining: -28108.268s.  
68% 3399/5000 [4:04:42<1:53:20, 4.25s/it]  
Epoch [3400/5000], Step [496000/200000]:  
Total Loss: 0.0701, Mel Loss: 0.0171, Mel PostNet Loss: 0.0146, Duration Loss: 0.0129, F0 Loss: 0.0111, Energy Loss: 0.0145;  
Time Used: 14686.881s, Estimated Time Remaining: -25293.144s.  
68% 3424/5000 [4:06:28<1:51:39, 4.25s/it]  
Epoch [3425/5000], Step [497000/200000]:  
Total Loss: 0.0725, Mel Loss: 0.0174, Mel PostNet Loss: 0.0150, Duration Loss: 0.0149, F0 Loss: 0.0123, Energy Loss: 0.0128;  
Time Used: 14793.114s, Estimated Time Remaining: -25051.027s.  
69% 3449/5000 [4:08:15<1:49:16, 4.23s/it]  
Epoch [3450/5000], Step [498000/200000]:  
Total Loss: 0.0699, Mel Loss: 0.0172, Mel PostNet Loss: 0.0148, Duration Loss: 0.0163, F0 Loss: 0.0094, Energy Loss: 0.0122;  
Time Used: 14899.330s, Estimated Time Remaining: -23188.184s.  
69% 3474/5000 [4:10:01<1:47:31, 4.23s/it]  
Epoch [3475/5000], Step [499000/200000]:  
Total Loss: 0.0753, Mel Loss: 0.0176, Mel PostNet Loss: 0.0152, Duration Loss: 0.0146, F0 Loss: 0.0085, Energy Loss: 0.0194;  
Time Used: 15005.266s, Estimated Time Remaining: -24814.563s.  
70% 3499/5000 [4:11:47<1:46:09, 4.24s/it]  
Epoch [3500/5000], Step [500000/200000]:  
Total Loss: 0.0757, Mel Loss: 0.0169, Mel PostNet Loss: 0.0145, Duration Loss: 0.0128, F0 Loss: 0.0095, Energy Loss: 0.0220;  
Time Used: 15111.476s, Estimated Time Remaining: -26373.893s.  
save model at step 500000 ...
```



```
Epoch [3300/5000], Step [492000/200000]:  
Total Loss: 0.0754, Mel Loss: 0.0173, Mel PostNet Loss: 0.0149, Duration Loss: 0.0126, F0 Loss: 0.0111, Energy Loss: 0.0194;  
Time Used: 14261.992s, Estimated Time Remaining: -25078.640s.  
66% 3324/5000 [3:59:23<1:58:18, 4.24s/it]  
Epoch [3325/5000], Step [493000/200000]:  
Total Loss: 0.0839, Mel Loss: 0.0177, Mel PostNet Loss: 0.0153, Duration Loss: 0.0193, F0 Loss: 0.0143, Energy Loss: 0.0172;  
Time Used: 14368.113s, Estimated Time Remaining: -24219.568s.  
67% 3349/5000 [4:01:10<1:56:54, 4.25s/it]  
Epoch [3350/5000], Step [494000/200000]:  
Total Loss: 0.0873, Mel Loss: 0.0177, Mel PostNet Loss: 0.0153, Duration Loss: 0.0218, F0 Loss: 0.0140, Energy Loss: 0.0185;  
Time Used: 14474.347s, Estimated Time Remaining: -25162.358s.  
67% 3374/5000 [4:02:56<1:54:55, 4.24s/it]  
Epoch [3375/5000], Step [495000/200000]:  
Total Loss: 0.0804, Mel Loss: 0.0172, Mel PostNet Loss: 0.0148, Duration Loss: 0.0202, F0 Loss: 0.0117, Energy Loss: 0.0164;  
Time Used: 14580.559s, Estimated Time Remaining: -28108.268s.  
68% 3399/5000 [4:04:42<1:53:20, 4.25s/it]  
Epoch [3400/5000], Step [496000/200000]:  
Total Loss: 0.0701, Mel Loss: 0.0171, Mel PostNet Loss: 0.0146, Duration Loss: 0.0129, F0 Loss: 0.0111, Energy Loss: 0.0145;  
Time Used: 14686.881s, Estimated Time Remaining: -25293.144s.  
68% 3424/5000 [4:06:28<1:51:39, 4.25s/it]  
Epoch [3425/5000], Step [497000/200000]:  
Total Loss: 0.0725, Mel Loss: 0.0174, Mel PostNet Loss: 0.0150, Duration  
Time Used: 14793.114s, Estimated Time Remaining: -25051.027s.  
69% 3449/5000 [4:08:15<1:49:16, 4.23s/it]  
Epoch [3450/5000], Step [498000/200000]:  
Total Loss: 0.0699, Mel Loss: 0.0172, Mel PostNet Loss: 0.0148, Duration  
Time Used: 14899.330s, Estimated Time Remaining: -23188.184s.  
69% 3474/5000 [4:10:01<1:47:31, 4.23s/it]  
Epoch [3475/5000], Step [499000/200000]:  
Total Loss: 0.0753, Mel Loss: 0.0176, Mel PostNet Loss: 0.0152, Duration  
Time Used: 15005.266s, Estimated Time Remaining: -24814.563s.  
70% 3499/5000 [4:11:47<1:46:09, 4.24s/it]  
Epoch [3500/5000], Step [500000/200000]:  
Total Loss: 0.0757, Mel Loss: 0.0169, Mel PostNet Loss: 0.0145, Duration  
Time Used: 15111.476s, Estimated Time Remaining: -26373.893s.  
save model at step 500000 ...
```

Synthesized Spectrogram



생성된 음성 파일 시청(試聽)



참고 문헌 및 자료



참고 문헌

- GitHub.io
 - <https://joungeekim.github.io/2021/04/01/code-review>
- GitHub
 - HGU-DLLAB / Korean-FastSpeech2-Pytorch
 - JH-lee95 / FastSpeech2-Korean

참고 자료

- Title Photo
 - 이담 엔터테인먼트 소속사 제공 – 아이유 프로필 사진
 - Dataset Sources
 - Kaggle – Korean Single Speaker Speech Dataset, Kyubyong Park
 - Youtube Channel – EDAM Entertainment
- Video Title : [집콕시그널] 아이유와 함께하는 집콕바캉스 (Live) [Full]





감사합니다.

tomtomato@naver.com

<https://github.com/yangchangnaihoby>